

# Deteksi Motif Batik Menggunakan Ekstraksi Tekstur dan Jaringan Syaraf Tiruan

*Batik Motif Detection Using Texture Extraction and Artificial Neural Networks*

**Raynaldi Fatih Amanullah\*<sup>1</sup>, Ade Pujianto<sup>2</sup>, Bayu Trisna Pratama<sup>3</sup>, Kusrini<sup>4</sup>**

<sup>1,2,3,4</sup> Magister Teknik Informatika, Universitas AMIKOM Yogyakarta

Jl Ring Road Utara, Condongcatur, Sleman, Yogyakarta 55281

e-mail: \*<sup>1</sup>raynaldi.a@students.amikom.ac.id, <sup>2</sup>ade.pujianto@students.amikom.ac.id,

<sup>3</sup>bayu.pratama@students.amikom.ac.id, <sup>4</sup>kusrini@amikom.ac.id

## Abstrak

Penelitian ini mengajukan sebuah metode klasifikasi batik menggunakan ekstraksi fitur tekstur serta klasifikasi menggunakan jaringan syaraf tiruan (artificial neural network). Metode ekstraksi fitur tekstur yang digunakan adalah DWT, GLCM dan Local Binary Pattern (LBP). Ekstraksi fitur dengan GLCM dan DWT menghasilkan 24 fitur yang terdiri dari 5 fitur GLCM dan koefisien energi dalam 4 sub-band channel hasil dekomposisi. Sementara ekstraksi fitur dengan LBP dilakukan dengan membangun histogram dari matriks hasil LBP. Fitur-fitur tersebut kemudian menjadi masukan bagi jaringan syaraf tiruan untuk kemudian diklasifikasi dalam 5 jenis batik: buketan, ceplok, kawung, parang dan truntum. Dataset yang digunakan adalah 50 gambar batik (10 untuk setiap motif) yang diambil secara acak di internet. Pengujian dilakukan dengan membandingkan dua kelompok fitur: DWT-GLCM dan DWT-GLCM-LBP untuk mengetahui metode ekstraksi fitur yang lebih baik dalam deteksi motif batik. Metode pengujian yang digunakan adalah K-Fold Cross Validation dengan hasil berupa confusion matriks untuk kemudian dihitung nilai akurasi dan F-Measure-nya. Hasil pengujian menunjukkan bahwa penggunaan ekstraksi fitur tekstur DWT-GLCM-LBP mampu mencapai akurasi 74% dengan jenis dekomposisi Daubechies 4 level 3.

**Kata kunci** — Klasifikasi Batik, GLCM, DWT, LBP, ANN.

## Abstract

This research proposes a method for batik image classification using texture features extraction and artificial neural network (ANN) as classifier. Texture extraction methods which are used in this research are DWT, GLCM and Local Binary Pattern (LBP). Texture extraction using GLCM and DWT produces 24 features consisting of 5 GLCM features and 4 energy coefficients in every sub-band channels of decomposition result. While texture extraction using LBP is done by constructing a histogram of the LBP result matrix. These features become input for artificial neural networks to be classified into 5 types of batik: buketan, ceplok, kawung, machetes and truntum. The dataset which is used consists of 50 batik images (10 for each motif) which are taken randomly from the internet. Testing is done by comparing two groups of features: DWT-GLCM and DWT-GLCM-LBP to find a better feature extraction method in batik motif detection. Testing method which is used is K-Fold Cross Validation. From that method we can construct confusion matrix then calculate Accuracy and F-Measure value. The test result shows that the use of DWT-GLCM-LBP texture extraction is able to achieve a percentage Accuracy of 74 on Daubechies 4 at 3<sup>rd</sup> level.

**Keywords**— Batik Classification, GLCM, DWT, LBP, ANN.

## 1. PENDAHULUAN

Batik merupakan kain dengan gaya, warna serta tekstur yang mencerminkan Budaya Indonesia. Batik sendiri telah dikenal dunia sejak beberapa abad yang silam oleh bangsa Indonesia. Oleh karena itu batik menjadi salah satu aset kekayaan budaya Indonesia dan telah diakui oleh UNESCO sebagai warisan budaya asli Indonesia pada tanggal 2 Oktober 2009 [1].

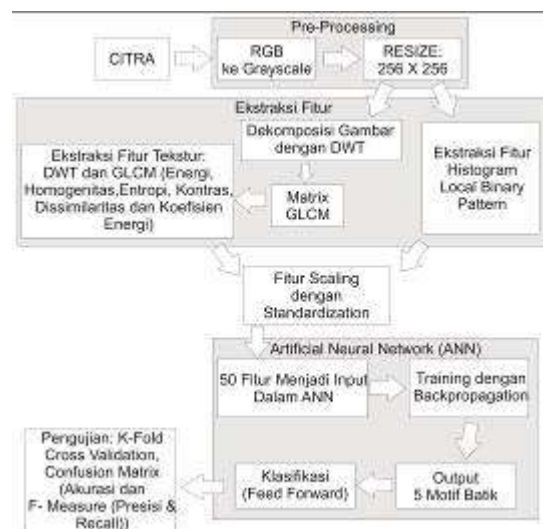
Pola penyusun batik dapat disebut dengan motif, berdasarkan ornamen dan strukturnya, jenis batik dapat diklasifikasikan sesuai motif dasarnya [2]. Di setiap daerah di Indonesia memiliki motif yang berbeda-beda, motif batik sendiri secara garis besar terbagi menjadi dua kelompok yaitu jenis motif geometris dan motif non-geometris, beberapa contoh motif batik diantaranya adalah buketan, ceplok, kawung, parang dan truntum.

Metode yang telah digunakan dalam melakukan ekstraksi fitur pada batik antara lain mengkombinasikan *Grey Level Co-Occurance Matrix* (GLCM) dan *Discrete Wavelete Transform* (DWT) [3], kombinasi *Hue Saturation Value* (HSV) dan *Discrete Curvelet Transform* [4], *Scale Invariant Feature Transform* dan *Support Vector Machine* [5].

Dalam penelitian ini diusulkan sebuah metode klasifikasi motif batik dengan menggunakan metode ekstraksi fitur Local Binary Pattern, Discrete Wavelet Transform (DWT) dan Gray Level Co-Occurrence Matrix (GLCM). Hasil dari ekstraksi fitur tersebut akan menjadi input bagi jaringan syaraf tiruan (*artificial neural network*).

Hasil dari penggunaan metode tersebut akan diuji dengan skema K-Fold Cross Validation untuk kemudian dihasilkan confusion matriks dan dihitung nilai akurasi, presisi dan recall-nya.

Alur penelitian ini dapat dilihat pada Gambar 1:



Gambar 1. Alur Penelitian

## 2. METODE PENELITIAN

### 2.1. Dataset


Dalam penelitian ini menggunakan dua jenis dataset untuk melakukan pengukuran terhadap ekstraksi fitur batik. Dimana dataset yang pertama berupa gambar acak yang diambil dari internet, sedangkan dataset kedua merupakan dataset utama yang didalamnya terdapat lima jenis batik, seperti buketan, ceplok, kawung, parang dan teruntum. Setiap jenis terdapat 10 gambar batik, sehingga jumlah keseluruhan pada dataset utama adalah 50 gambar. Dari dataset tersebut, 5 gambar batik digunakan sebagai data pengujian dan 45 sisanya digunakan sebagai *training*.

## 2.2. Preprocessing

Terdapat dua tahap preprocessing pada dataset utama. Pertama, melakukan perubahan ukuran gambar menjadi 256 x 256. Selanjutnya gambar yang telah dirubah ukurannya akan di konversi menjadi gambar keabu-abuan (*greyscale*).

## 2.3. Local Binary Pattern (LBP)

LBP merupakan operator yang berguna untuk mendeskripsikan fitur berdasarkan tanda-tanda perbedaan yang ada antara piksel sisi dengan piksel *central* (tengah) [6]. Untuk contoh perhitungan LBP akan dijelaskan Gambar 2. Setiap nilai yang dihasilkan dari citra, nantinya akan diubah menjadi nilai *binary* yang disebut dengan *thresholding*, dengan nilai tengah yang tetap.




Gambar 2. Perhitungan LBP

Nilai *threshold* diperoleh dengan cara membandingkan nilai sisi (tepi) dengan nilai tengah, apabila nilai tepi lebih besar atau sama dengan nilai tengah maka bernilai 1, namun apabila nilai sisi lebih kecil dari nilai tengah akan bernilai 0. Selanjutnya membuat sebuah matriks dengan nilai  $2^n$ , yang mana dari matriks tersebut tidak terdapat nilai tengah. Selanjutnya matriks yang berisi *binary* dikalikan dengan matriks yang berisikan nilai *kuadrat*, seperti yang terlihat dalam Persamaan (1). Setelah mendapatkan hasil dari perkalian tersebut, maka nilai sisi dijumlahkan, yang mana jumlah tersebut nantinya diisikan pada piksel *central*.

$$LBP(x_c, y_c) = \sum_{n=0}^7 2^n g(I_n - I(x_c, y_c)) \quad \dots(1)$$

## 2.4. Discrete Wavelet Transform (DWT)

DWT membagi sinyal menjadi dua spektrum frekuensi, yakni frekuensi tinggi dan frekuensi rendah. Frekuensi tinggi biasa disebut dengan koefisien wavelet sedangkan frekuensi rendah disebut dengan koefisien aproksimasi. Agar dapat menangkap dua spektrum frekuensi tersebut, DWT menggunakan dua *filter*, yaitu *high pass filter* disimbolkan dengan  $g[n]$  yang digunakan untuk menangkap spektrum frekuensi tinggi dan *low pass filter* disimbolkan dengan  $h[n]$  untuk menangkap spektrum frekuensi yang lebih rendah. Koefisien hasil aproksimasi kemudian diproses kembali menggunakan kedua *filter* tersebut hingga mencapai level tertentu [7].



Gambar 3. DWT Dua Level

Dari Gambar 3 memperlihatkan dua level dekomposisi. Mula-mula sinyal  $S$  dilewatkan *high pass filter* dan *low pass filter* kemudian melakukan proses *downsampling* secara berturut-turut menghasilkan koefisien  $cD1$  dan  $cA1$ . Koefisien  $cA1$  diproses kembali dan menghasilkan  $cD2$  dan  $cA2$ . Berikutnya koefisien tersebut di rekonstruksi dua level sehingga menghasilkan sinyal  $S$  kembali.


Operasi pemfilteran dan *subsampling* dapat dituliskan sebagai berikut:

$$y_{high}[k] = \sum_n x[n]g[2k - n].....(2)$$

$$y_{low}[k] = \sum_n x[n]h[2k - n].....(3)$$

Dimana  $g[n]$  dan  $h[n]$  secara berturut-turut adalah *high pass* dan *low pass filter*. Hasil dekomposisi pada persamaan 2 adalah berupa aproksimasi sinyal yang memuat separuh dari resolusi waktu sinyal aslinya. Jumlah sampel sinyal juga berkurang menjadi separuh dari aslinya [8].

Selanjutnya dilakukan proses transformasi pada baris dan kolomnya. Pertama-tama transformasi dilakukan pada semua baris kemudian hasil transformasi dari baris ditransformasikan pada semua kolomnya seperti yang ditunjukkan Gambar 4.




Gambar 4. Transformasi Citra Dua Dimensi


Dari Gambar 4 menunjukkan transformasi citra dua dimensi yang menghasilkan tiga level subband. Setiap level dekomposisi menghasilkan empat subband yaitu: detail aproksimasi (LL), detail horizontal (LH), detail vertikal (LH) dan detail diagonal (HH) [9].

## 2.5. Gray Level Co-Occurance Matrix (GLCM)

GLCM merupakan suatu matriks yang berbentuk persegi atau bujursangkar, dengan panjang sisi adalah jumlah tingkat keabu-abuan gambar. Matriks tersebut berisikan nilai-nilai probabilitas yang tersusun atas dua piksel, yaitu  $i$  dan  $j$ . Dengan masing-masing nilai yang dbatasi oleh jarak dan arah. Jarak disini dapat berupa sudut 0, 45°, 90°, 135°, 180°, 225°, 270°, 325°. Sedangkan untuk arahnya, dapat dilihat pada Gambar 5. Untuk GLCM akan dijelaskan pada Gambar 6.



Gambar 5. Arah sudut



Gambar 6. GLCM (a) Matrix Keabu-abuan, (b) GLCM, (c) Co-Occurrence matrix, (d) nilai probabilitas.

Selanjutnya, setelah matrix terbentuk, maka dilakukannya perhitungan-perhitungan statistik seperti Entropi, Kontras, Homogeneitas, dan Energi. Entropi merupakan ekstraksi fitur yang digunakan untuk mengukur keteracakan dari distribusi intensitas [10]. Formula yang dapat dipakai untuk menghitung entropi ditunjukkan oleh Persamaan (4).

$$Entropi = - \sum_{i_1} \sum_{i_2} p(i_1, i_2) \log p(i_1, i_2) \dots (4)$$

Energi adalah fitur untuk mengukur konsentrasi pasangan intensitas pada matrix *co-occurrence* [10]. Persamaan yang digunakan untuk menghitung energi adalah Persamaan (5) [10]. Nilai energi akan makin membesar bila pasangan piksel yang memenuhi syarat matriks intensitas *co-occurrence* terkonsentrasi pada beberapa koordinat dan mengecil bila letaknya menyebar.

$$Energi = \sum_{i_1} \sum_{i_2} p^2(i_1, i_2) \dots (5)$$

Kontras adalah fitur yang digunakan untuk mengukur kekuatan perbedaan intensitas dalam citra [10]. Nilai kontras membesar jika variasi intensitas citra tinggi dan menurun bila variasi rendah. Persamaan yang digunakan untuk mengukur kontras suatu citra ditunjukkan pada Persamaan (6) [10].

$$Kontras = \sum_{i_1} \sum_{i_2} (i_1 - i_2)^2 p(i_1, i_2) \dots (6)$$

Homogeneitas digunakan untuk mengukur kehomogenan variasi intensitas citra [10]. Nilai homogeneitas akan semakin membesar bila variasi intensitas dalam citra mengecil. Homogeneitas dihitung dengan Persamaan (7) [10].

$$Homogeneitas = \sum_{i_1} \sum_{i_2} \frac{p(i_1, i_2)}{1 + |i_1 - i_2|} \dots (7)$$

Notasi  $p$  pada Persamaan (4), (5), (6), dan (7) melambangkan probabilitas yang bernilai nol hingga 1, yaitu nilai elemen dalam matriks *co-occurrence*, sedangkan  $i_1$  dan  $i_2$  melambangkan pasangan intensitas yang berdekatan, yang dalam matriks *co-occurrence* masing-masing menjadi nomor baris dan nomor kolom.

## 2.6. Artificial Neural Network (ANN)

ANN merupakan jaringan yang memodelkan sistem saraf otak manusia [11] menggunakan neuron yang disusun menurut arsitektur tertentu. Otak manusia sangatlah kompleks, non linear dan memproses informasi secara paralel serta memiliki kemampuan untuk mengorganisasi neuron agar dapat mengenali pola secara efektif [12].

Kemampuan otak itulah yang coba diadopsi oleh ANN. Namun pemodelan pada ANN jauh lebih sederhana dibandingkan otak manusia. ANN menggunakan unit pemrosesan yang sederhana untuk mengenali pola atau melakukan fungsi tertentu. Masing-masing unit pemrosesan menggunakan *state* dinamisnya untuk memproses informasi yang diterimanya. *Neural Network* merespon *input* eksternal yang diberikan melalui *input layer*.

### 2.7. K-Fold Cross Validation

Metode *k-Fold Cross Validation* digunakan untuk memvalidasi model *classifier*. Metode ini membagi himpunan menjadi  $k$  bagian secara acak dan saling bebas [11]. Data sebanyak  $(k-1)$  fold digunakan untuk melatih model sedangkan 1 fold digunakan untuk melakukan pengujian. Validasi dilakukan sebanyak  $k$  kali hingga semua data dalam dataset diujikan pada model.

### 2.8. Confusion Matrix

*Confusion Matrix* merupakan metode yang dapat digunakan untuk mengukur kinerja suatu metode klasifikasi. Pada dasarnya metode ini mengandung informasi yang membandingkan hasil klasifikasi yang dilakukan oleh sistem dengan hasil klasifikasi yang seharusnya [13]. Pada pengukuran kinerjanya, terdapat empat istilah sebagai representasi hasil proses klasifikasi. Keempat istilah tersebut adalah *True Positive* (TP), *True Negative* (TN), *False Positive* (FP), dan *False Negative* (FN) seperti pada Gambar 7.

		Predicted class	
		P	N
Actual Class	P	True Positives (TP)	False Negatives (FN)
	N	False Positives (FP)	True Negatives (TN)

Gambar 7. Confusion Matrix

Berdasarkan Gambar 7 dapat diperoleh nilai akurasi, presisi dan *recall*. Nilai akurasi menggambarkan seberapa akurat sistem mengklasifikasi data secara benar, nilai akurasi diperoleh dari Persamaan (8). Nilai presisi menggambarkan jumlah data kategori positif yang diklasifikasikan secara benar dan dibagi dengan total data yang diklasifikasi positif, dan nilai presisi diperoleh dari Persamaan (9). *Recall* menunjukkan beberapa persen data kategori positif yang terklasifikasi dengan benar oleh sistem, nilai *recall* diperoleh dari Persamaan (10). Sedangkan F-Measure merupakan perhitungan *information retrieval* yang mengkombinasikan *recall* dan *presisi*. Nilai F-Measure diperoleh dari Persamaan (11).

$$Akurasi = \frac{TP+TN}{TP+TN+FP+FN} \times 100\% \quad \dots(8)$$

$$Presisi = \frac{TP}{FP+TP} \times 100\% \quad \dots(9)$$

$$Recall = \frac{TP}{FN+TP} \times 100\% \quad \dots(10)$$

$$F - Measure = 2 \times \frac{Presisi \times Recall}{Presisi + Recall} \quad \dots(11)$$

## 3. HASIL DAN PEMBAHASAN




Terdapat 2 kelompok fitur yang digunakan dalam penelitian ini yaitu LBP dan DWT + GLCM. Ekstraksi fitur dengan LBP menghasilkan 26 fitur yang merupakan histogram dari kemunculan nilai dalam piksel hasil LBP. Sedangkan ekstraksi fitur dengan DWT dan GLCM menghasilkan 24 fitur. 2 jenis fitur tersebut dilakukan dua skenario pengujian: DWT + GLCM tanpa menggunakan LBP dan DWT + GLCM dengan menggunakan LBP. Hal ini dilakukan untuk mengetahui metode ekstraksi fitur mana yang mampu memiliki tingkat hasil uji yang lebih tinggi. Fitur-fitur ini kemudian di normalisasi datanya untuk memperkecil range data sebelum kemudian menjadi input dari algoritma jaringan syaraf tiruan.

Dalam jaringan syaraf tiruan, digunakan 1 hidden layer yang memiliki 10 neuron dan 1 layer output yang memiliki 5 neuron yang diperoleh dari jumlah motif batik yang dihasilkan.

Pengujian pada 2 perbandingan fitur dilakukan dengan 2 skenario pengujian yaitu perubahan max epoch dan perubahan jenis dan level dekomposisi. Skema pengujian yang digunakan adalah K-Fold Cross Validation dengan nilai K sebesar 10. 50 dataset dibagi ke dalam 10 fold sehingga menghasilkan 5 data uji dan 45 data training. Dari K-Fold Cross Validation dihasilkan Confusion Matrix untuk kemudian dihitung nilai akurasi dan F-Measure (dari nilai presisi dan recall).

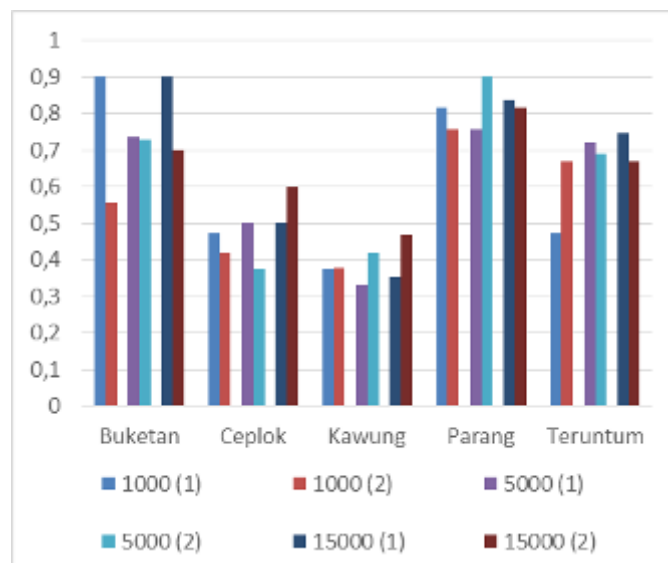
Dalam setiap skenario pengujian diinisialisasikan nilai learning rate sebesar 0.2, momentum sebesar 0.8, dan ambang batas error sebesar 0.01. Hasil pengujian dengan skenario pertama yaitu perubahan max epoch dengan dekomposisi menggunakan Haar level 1 diperoleh hasil akurasi sebagai berikut:



Gambar 8. Grafik Akurasi Hasil Penggunaan Fitur Dengan 6 Besaran Max Epoch yang Berbeda

Gambar 8 menunjukkan bahwa pada Haar level 1, ekstraksi fitur dengan GLCM + DWT tanpa LBP berhasil dengan lebih baik pada 3 besaran max epoch yang berbeda.

Selain mengukur nilai akurasi, nilai F-Measure juga diukur pada masing-masing motif batik. Berikut Gambar 9 yang menunjukkan perbandingan nilai F-Measure pada masing-masing max epoch dengan ekstraksi fitur GLCM + DWT ditunjukkan oleh angka (1) dan DWT + GLCM + LBP ditunjukkan oleh angka (2):




Gambar 9. Nilai F-Measure pada masing-masing batik dan fitur

Sebagaimana nilai akurasi, nilai F-Measure tertinggi pada masing-masing motif batik juga didominasi oleh hasil ekstraksi fitur dengan GLCM + DWT. Ekstraksi fitur dengan GLCM + DWT + LBP hanya unggul pada motif batik ceplok pada max epoch 15000, semua max epoch kawung, dan teruntum pada max epoch 1000.

Pada skenario pengujian kedua, dilakukan uji coba perubahan jensi dan level dekomposisi untuk mengetahui bagaimana pengaruh jenis dan level dekomposisi terhadap nilai akurasi dan F-Measure.

Berikut gambar 10 yang menunjukkan perbandingan nilai akurasi antara ekstraksi fitur dengan GLCM +DWT dan GLCM + DWT + LBP pada level dan jenis dekomposisi tertentu:



Gambar 10. Grafik Perbandingan Nilai Akurasi

Dari gambar 10 kita bisa menyimpulkan bahwa penggunaan ekstraksi fitur dengan LBP mampu meningkatkan nilai akurasi pada sebagian besar parameter pengujian.

Sedangkan perbandingan nilai F-Measure pada masing-masing motif batik dengan ekstraksi fitur DWT + GLCM yang ditunjukkan oleh angka (1) dan DWT + GLCM + LBP yang ditunjukkan oleh angka (2) pada jenis dan level dekomposisi tertentu ditunjukkan oleh Tabel 1 berikut ini dengan penulisan tebal yang menunjukkan nilai yang lebih besar pada jenis dan level dekomposisi tersebut:



Tabel 1. Tabel Nilai F-Measure Ekstraksi Fitur pada Jenis dan Level Dekomposisi Tertentu

Jenis Batik	Jenis DWT	Ekstraksi Fitur	Level		
			1	2	3
Buketan	Haar	(1)	<b>0.9</b>	$\frac{0.5}{6}$	0.5
		(2)	0.7	<b><math>\frac{0.7}{2}</math></b>	<b>0.67</b>
	Db4	(1)	0.7	0.5	0.54
		(2)	<b>0.78</b>	<b><math>\frac{0.5}{6}</math></b>	<b>0.84</b>
Ceplok	Haar	(1)	0.5	$\frac{0.5}{2}$	0.48
		(2)	<b>0.6</b>	<b><math>\frac{0.5}{8}</math></b>	<b>0.55</b>
	Db4	(1)	0.37	0.5	0.47
		(2)	<b>0.73</b>	<b>0.4</b>	<b>0.63</b>
Kawung	Haar	(1)	0.35	$\frac{0.3}{3}$	<b>0.5</b>
		(2)	<b>0.47</b>	<b><math>\frac{0.4}{7}</math></b>	0.4
	Db4	(1)	<b>0.45</b>	<b><math>\frac{0.4}{2}</math></b>	0.42
		(2)	$\frac{0.37}{5}$	$\frac{0.3}{1}$	<b>0.44</b>
Parang	Haar	(1)	<b>0.84</b>	$\frac{0.8}{5}$	0.7
		(2)	0.81	<b><math>\frac{0.8}{7}</math></b>	<b>0.8</b>
	Db4	(1)	0.8	$\frac{0.6}{9}$	0.8
		(2)	<b>0.82</b>	<b><math>\frac{0.7}{5}</math></b>	<b>0.86</b>
Truntum	Haar	(1)	<b>0.75</b>	0.8	0.7
		(2)	0.67	<b><math>\frac{0.8}{5}</math></b>	<b>0.76</b>
	Db4	(1)	0.6	<b><math>\frac{0.6}{3}</math></b>	0.63
		(2)	<b>0.8</b>	0.5	<b>0.9</b>

Pada tabel 1 dapat dilihat bahwa ekstraksi fitur dengan DWT + GLCM + LBP memperoleh hasil yang lebih baik dengan 23 keunggulan dibanding dengan tanpa LBP yang hanya memperoleh 7 keunggulan.

#### 4. KESIMPULAN

Penelitian ini mengusulkan penggunaan metode ekstraksi tekstur serta klasifikasi dengan jaringan syaraf tiruan untuk mengklasifikasi jenis-jenis motif batik. Metode ekstraksi fitur tekstur yang digunakan adalah kombinasi GLCM dan DWT yang dibandingkan dengan GLCM, DWT dan LBP untuk mengetahui kombinasi fitur mana yang memperoleh hasil yang lebih baik.

Dari hasil ujicoba yang telah dilakukan menunjukkan bahwa dengan menggunakan dekomposisi Haar level 1, penggunaan ekstraksi tekstur dengan GLCM dan DWT tanpa LBP mampu memperoleh hasil yang lebih baik dalam berbagai kondisi maksimal epoch yang berbeda baik dalam nilai akurasi maupun nilai F-Measure. Akan tetapi pada level dekomposisi 2-3 dengan jenis dekomposisi haar maupun daubechies 4, kombinasi GLCM, DWT dan LBP terbukti mampu memperoleh nilai akurasi dan F-Measure yang lebih baik dengan nilai akurasi tertinggi diperoleh pada penggunaan jenis dekomposisi Daubechies 4 level 3 dengan nilai akurasi 74%.

## 5. SARAN

Untuk penelitian selanjutnya, dapat digunakan fitur-fitur yang berguna untuk mendeteksi shape (bentuk) seperti edge detection agar dapat meningkatkan hasil akurasi khususnya pada motif-motif batik yang memiliki tingkat kemiripan yang tinggi seperti kawung dan ceplok.

## DAFTAR PUSTAKA

- [1] UNESCO, 2009, Intangible Cultural Heritage, <https://ich.unesco.org/en/RL/indonesian-batik-00170>, diakses tanggal 11 December 2017.
- [2] H. S. Doellah, 2002, *Batik: Pengaruh Zaman dan Lingkungan*, Batik Danar Hadi, Solo.
- [3] A. E. Minarno, Y. Munarko, A. Kurniawandhani, F. Bimantoro and N. Suciati, 2014 Texture Feature Extraction Using Co-Occurance Matrices of Sub-Band Image For Batik Image Classification, *International Conference on Information and Communication Technology (ICoICT)*, Bandung.
- [4] N. Suciati, A. Kridanto, M. F. Naufal, M. Machmud and A. Y. Wicaksono, 2015, Fast Discrete Curvelet Transform and HSV Color Features For Batik Image Classification, *International Conference on Information, Communication Technology and System (ICTS)*, Surabaya.
- [5] R. Azhar, D. Tuwohingide, D. Kamudi, S. and N. Suciati, "Batik Image Classification, 2015, Using SIFT Feature Extraction, Bag of Features and Support Vector Machine, *Information Systems International Conference*, Surabaya.
- [6] E. Prakasa, 2015, Texture Feature Extraction by Using Local Binary Pattern, *Journal of Informatics, Control Systems, and Computers*, vol. 9, no. 2, pp. 45-48.
- [7] L. F. D., 2009, *Conceptual Wavelets in Digital Signal Processing*, Space and Signals Technical Publisher, United States of America.
- [8] M. Darshana and B. Asim, 2013, Discrete Wavelet Transform Using MATLAB, *International Journal of Computer Engineering and Technology*, vol. 4, no. 2, pp. 252-259.
- [9] R. Polikar, 2001, Index to Series Of Tutorials to Wavelet Transform By Robi Polikar, <http://users.rowan.edu/~polikar/WAVELETS/WTtutorial.html>, diakses tanggal 11 December 2017.
- [10] A. U, 2005, *Pengolahan Citra Digital*, Penerbit Graha Ilmu, Yogyakarta.

- [11] Suyanto, 2017, *Data Mining untuk Klasifikasi dan Klasterisasi Data*, Penerbit INFORMATIKA, Bandung.
- [12] S. Haykin, 1999, *Neural Networks - A Comprehensive Foundation, 2nd ed*, Indian Branch, Delhi.
- [13] E. Prasetyo, 2012, *Data Mining: Konsep dan Aplikasi Menggunakan Matlab, 1st ed*, ANDI Publisher, Yogyakarta.